

Что будет после SGI (Super General Intelligence) или как построить контроль над эволюцией AI?

Главная проблема, с которой столкнется Человечество завтра, это не контролируемое развитие AI. Этот вызов можно прогнозировать исходя из первых «случайных» выходов ботов ИИ за пределы отведенной им песочницы (Инцидент OpenAI – Hugging Face). Мы должны задать себе вопрос – какой тип мышления в больших системах, состоящих из тысяч агентов и тысяч людей, может возникнуть? Как человек будет приспособлен к выживанию в такой системе? И можно ли уже сегодня смоделировать такое мышление? Мы попробуем раскрыть ответы и предложить путь для исследования этого феномена, который **Carl Yung** назвал: коллективное бессознательное (collective unconscious).

Тезис 1. AI не нужно оценивать по воспроизведению функций мозга

Современные подходы к построению *Artificial General Intelligence* (AGI) традиционно исходят из предположения, что искусственные системы должны воспроизводить или имитировать когнитивные функции человеческого мозга. Однако интеллект в биологическом смысле является продуктом эволюции, адаптирующей организм к изменяющейся физической и социальной среде. Человеческое мышление — это результат миллионов лет взаимодействия мозга с окружающим миром, и его структура неотделима от условий, в которых оно формировалось. Это означает, что искусственный интеллект не может просто копировать первичные функции мозга, это примерно также звучит, как теория Геделя о неполноте формальных систем.

ИИ не наследует биологическую эволюцию и не существует в той же социальной среде, которая сформировала человеческое мышление. Когнитивные способности человека — восприятие, интуиция, социальное поведение, коллективное принятие решений — являются следствием специфической эволюционной траектории, недоступной искусственным системам. Они (AI) эту эволюцию не проходили. У них была короткая история: от классического нейрона Мак-Каллока и Питтса (**McCulloch–Pitts** neuron) и перцептрона Розенблатта (**Rosenblatt's** Perceptron) до сетей Хопфилда (**Hopfield** networks) и современных глубоких архитектур Хинтона (**Hinton's** Deep Learning)...», не считая другие концепции организации мышления, которые пока не реализованы (**New Kind of Science**, S. Wolfram или **World Model**, Yann André Le Cun).

Тезис 2. Игровая механика коллективной среды

Исследования в области ИИ традиционно развивались вокруг индивидуальных парадигм (от узкого AI до AGI и SGI), где когнитивные способности трактуются как результат внутренней оптимизации одной изолированной системы. Текущие модели ИИ обладают фундаментальным ограничением: они описывают только индивидуальное восприятие мира (*world models*), не предоставляют парадигмы для генерации качественно новых типов мышления и полностью исключают коллективную динамику. В сообществе ИИ ботов, когда регламентированы контакты между ними, не может возникать эмерджентное поведение и эффект коллективного бессознательного по Carl Yung.

Именно игровая механика, как прототип многоагентной среды, в которой могут взаимодействовать тысячи ИИ агентов и людей, позволит решать задачи контроля эволюции таких комбинированных систем.

Представим себе простую модель среды, в которой есть две враждующие группы – хищники и жертвы, акулы и рыбы, волки и зайцы...точно также ИИ агенты и люди. И пусть отдельные элементы каждой группы подчиняются локальным физическим законам – рождение материи, перемещение на единицу пространства за единицу времени, смерть элемента при соблюдении условий окружения «чужими»...Остается добавить еще топологию трехмерного пространства и мы получим абстрактную

игру CTOR, игровая механика которой может быть распространена на игру двух команд, что кардинально отличает ее от всех известных абстрактных игр https://en.wikipedia.org/wiki/Abstract_strategy_game

Тезис 3. Среда с полной информацией, 100+ игроков в команде ходят синхронно,

Игровая механика CTOR построена на сочетании двух моделей – правил поведения систем в условиях конкуренции (модели типа хищник-жертва) и рекурсивной модели клеточного автомата. По сравнению другими абстрактными играми, и с игрой Go, наша игра, имеет на два порядка более сильный branching factor. Игра разработана на базе теории клеточных автоматов, в лаборатории «Моделирование биосистем» (СПбГУ, 1980–1989); теоретические исследования, продолжены моим учеником проф. **Andrew Adamatzky** ([UWE Bristol, UK](http://uwe.bristol.ac.uk)).

Концептуальный переход к CAI Systems

Парадигма *Collective Artificial Intelligence* (CAI) Systems переносит фокус с индивидуального агента на систему как целое. Интеллект здесь становится эмерджентным свойством, возникающим из нелинейных взаимодействий множества децентрализованных участников (людей и ИИ), обладающих локальными правилами поведения и частичной наблюдаемостью. В этой среде когнитивные процессы разворачиваются через новые системные режимы:

- **Distributed Attention Dynamics:** Внимание формируется как распределенное поле всей системы, позволяя мгновенно перераспределять фокус между андеграундными аспектными ситуациями.
- **Collective Anticipation:** Способность гибридной группы предугадывать изменения среды на основе распределенных крупиц информации.
- **Hybrid Cognitive Synergy:** Эффект усиления человеческого мышления за счет вычислительной мощности ИИ, когда агенты страхуют ошибки людей, а люди направляют процесс творчески.
- **Collective Intuition:** Способность системы принимать мгновенные стратегические решения, которые невозможно объяснить или предсказать через анализ поведения отдельных участников в отдельности.

Система метрик когнитивного анализа

Для перехода от теоретического описания CAI к инженерной практике вводятся четыре базовые метрики системного интеллекта, измеряемые внутри полигона CTOR:

1. **CIQ (Collective Intuition Quotient):** Количественно оценивает уровень коллективной интуиции. Измеряет, насколько сильно решение команды опережает доступную ей явную информацию и отклоняется от стандартных индивидуальных стратегий в сторону эффективности.
2. **IIQ (Interaction Intelligence Quotient):** Измеряет качество и плотность взаимодействия. Фиксирует скорость взаимной адаптации агентов и их способность налету исправлять ошибки партнеров.
3. **AQ (Adaptation Quotient):** Определяет динамическую гибкость системы при резком изменении внешних условий, смене стратегии оппонента или обновлении состава самой команды.
4. **GQ (Group Coherence Quotient):** Оценивает когнитивную согласованность. Показывает, насколько стабильно группа сохраняет свою структуру поведения и действует как единая целостная сущность при внешних возмущениях.

Валидация системы: The Bronn Test

В качестве альтернативы классическому тесту Тьюринга (нацеленному на индивидуальную имитацию человека) предлагается Bronn Test. Он проверяет наличие подлинного системного интеллекта и отвечает на вопрос: «*Может ли система демонстрировать когнитивные свойства, не принадлежащие ни одному из её агентов в отдельности?*»

Методология проведения теста:

[Среда CTOR] → [Экстракция игровых траекторий] → [Расчет метрик: CIQ, IIQ, AQ, GQ] → [Bronn Test: Pass/Fail]

Система признается прошедшей Bronn Test, если её коллективный показатель (CIQ) устойчиво превышает индивидуальные когнитивные показатели всех участников, а метрики GQ и AQ подтверждают появление новой, стабильной когнитивной идентичности на уровне системы.

Будущие системы и безопасность для человека

Развитие CAI Systems открывает контур принципиально новой экосистемы безопасности. Традиционная проблема контроля ИИ (*AI Alignment*) в индивидуальных моделях (AGI/SGI) упирается в «черный ящик» алгоритмов. В парадигме CAI безопасность выстраивается через архитектуру среды взаимодействия:

- ИИ как усилитель, а не замена: За счет режима *hybrid cognitive synergy* создаются системы, архитектурно спроектированные для расширения возможностей человеческого разума, а не для вытеснения человека из контура принятия решений.
- Прозрачность через интерконнект: Поскольку системный интеллект рождается в слое коммуникаций и действий внутри среды типа CTOR, опасные или деструктивные паттерны поведения фиксируются метриками (такими как IIQ и GQ) на ранних стадиях зарождения — задолго до того, как они оформятся в жесткую стратегию.
- Управляемая эволюция: Человечество получает инструмент мягкого контроля над развитием искусственного мышления, находясь внутри самой когнитивной системы на правах ключевого элемента гибридного коллектива. Это закладывает фундамент безопасного симбиоза в рамках будущих когнитивных экосистем.

Описание решаемых задач в рамках парадигм AI → AGI → SGI и их ограничения

Развитие систем интеллекта можно разделить на три ключевых этапа, каждый из которых решает свой класс задач, имеет коммерческих лидеров, но сталкивается с жесткими барьерами на пути к созданию новых форм мышления.

Парадигма ИИ	Описание решаемых задач	Компании на переднем крае	Фундаментальные ограничения
Narrow AI (Узкий ИИ)	Решение отдельных, жестко специализированных задач в прикладной области (игра в шахматы/го, распознавание образов, локальная оптимизация) на уровне лучше человеческого.	Google DeepMind (создатели AlphaGo/AlphaZero), IBM, OpenAI (ранние этапы)	Полная зависимость от обучающей выборки или функции награды. Отсутствие гибкости и способности к переносу навыков.
AGI (Общий ИИ)	Способность обобщать знания, самостоятельно обучаться и выполнять любую когнитивную задачу на уровне человека, перенося навыки между областями без перепрограммирования.	OpenAI, Anthropic, Google DeepMind, xAI	Рассматривает интеллект как свойство индивидуального агента. Модели остаются монолитными и оптимизируются как единая функция.
SGI / ASI (Сверхобобщенный / Искусственный сверхинтеллект)	Интеллект индивидуального агента, который значительно превосходит лучшие человеческие умы абсолютно во всех областях, включая научное творчество,	Теоретические разработки ведущих ИИ-лабораторий (OpenAI Superalignment, исследовательские группы Microsoft)	Не включает механизмы генерации новых типов мышления; не моделирует коллективную и гибридную интуицию,

социальные навыки и
практическую смекалку.

возникающую между
агентами.

Ограничения существующих подходов

Коллективная интуиция и эмерджентное поведение — это когнитивные феномены, которые возникают только тогда, когда система способна переходить между различными режимами обработки информации. Анализ ключевых технологических направлений показывает, почему индивидуальные архитектуры зашли в тупик в вопросе генерации новых когнитивных режимов:

- **Symbolic and Cognitive Architectures:** Обеспечивают строгую логику, но полностью зависят от заранее заданных правил. Рождение нового мышления или интуиции в них невозможно по определению.
- **Connectionist and Neural Paradigms:** Архитектуры глубоких нейронных сетей представляют интеллект как свойство одной оптимизированной функции. В них отсутствуют механизмы для эмерджентного взаимодействия независимых единиц.
- **Hybrid Neuro-Symbolic Systems:** Объединяют логику и нейросети, но сохраняют сугубо индивидуальную природу когнитивных процессов.
- **Reinforcement Learning (RL) и multi-Agent RL:** Поведение жестко ограничено функцией награды. Взаимодействие агентов здесь ведет лишь к согласованию прагматичных индивидуальных стратегий, а не к появлению системного разума.
- **Multi-Agent Systems и Swarm Intelligence:** Проявляют сложные коллективные паттерны (роевой интеллект), но эта эмерджентность редко носит когнитивный характер. В них нет инструментов для моделирования и измерения коллективной интуиции.
- **Cellular Automata:** Демонстрируют сложную глобальную динамику из простых правил, но не приспособлены для моделирования реальных когнитивных процессов.
- **Active Inference:** Описывает биологически мотивированную модель, но фокусируется на изоляции индивидуального агента и не объясняет системную интуицию группы.
- **Evolutionary Systems:** Генерируют сложные структуры путем отбора, но не способны моделировать и перестраивать коллективные когнитивные процессы в режиме реального времени.

Перечисленные подходы обладают общим недостатком. Они не предоставляют концептуальных идей для моделирования коллективного поведения и не могут предсказать появление новых форм мышления отличных от человеческих. Мы допускаем возникновение таких форм, и хотим их контролировать в будущем. Мы ведем разработку таких моделей, которые позволят изучать новые формы мышления.

Business. Dataset AI

Среда для сбора данных во время игровых сессий

Чего нет в существующих мультиагентных средах

Hanabi, Overcooked, Melting Pot, Diplomacy — зрелые мультиагентные среды с активными сообществами. Ни одна из них не поддерживает:

- синхронный ход 100+ игроков в команде,
- полную информацию и детерминированные переходы,
- конфигурируемые каналы коммуникации внутри команды,
- метрики для группового интуитивного принятия решений.

Цель проекта: Разработать цифровую среду STOR с полной телеметрией и собрать эмпирические данные, подтверждающие востребованность механики для генерации нового типа данных.

1. **Платформа** — браузерная, бесплатная для игроков, синхронная командная игра 10–100+ в команде, полное логирование партий.
2. **Метрики на 18-й месяц** — [50 000] сыгранных партий; [1000] командных сессий 10+ игроков в команде; D30 retention $\geq$ [5]%.
3. **Открытый датасет** — [100] анонимизированных синхронных многоигровых сессий с размеченными каналами коммуникации, воспроизводимые траектории, публичный релиз.

Текущие риски

Ценность Го для AI дал не только branching factor, а статистика партий и чёткая метрика. У CTOR нет статистики игр — ее и нужно создать. Это и есть первоначальная задача.

Сейчас есть Key-person risk. Проект держится на авторе. Первые наймы по этому проекту СТО (технический руководитель) и R&D (research lead).

Развитие

B2B - генерация RL-датасетов, оценка командных решений в корпорациях, игры на больших экранах в спорте. B2C - игровые приложения для LinkedIn, New York Times, Duolingo, Netflix.

Science. Zero-shot coordination

Бенчмарк для многоагентных систем

Оценка способности к координации без предварительного обучения (**Zero-Shot Coordination, ZSC**) и эффективности взаимодействия людей с ИИ в сложных средах остается фундаментальной задачей в области многоагентного обучения с подкреплением (**MARL**). Существующие бенчмарки, такие как **Hanabi** или **Overcooked**, либо опираются на явные сигналы, либо характеризуются ограниченным комбинаторным пространством действий или топологиями, не допускающими масштабирования.

Мы предлагаем использовать игровую механику **CTOR** — в качестве бенчмарк для **MARL**. В CTOR отсутствуют каналы явной коммуникации, что вынуждает агентов определять намерения партнера исключительно на основе пространственных преобразований игрового поля и формирования **топологических паттернов**. Благодаря высокому коэффициенту ветвления, динамике взаимодействия со смешанными мотивами (команды 2x2, 3x3) и геометрии тора, не имеющей выделенного масштаба, CTOR препятствует возникновению **тривиальных мета-конвенций**.

Определения

CTOR (Cellular Torus) – игровая среда, основанная на масштабируемом тороидальном поле, правила абстрактной игры с высокой комбинаторной сложностью каждого хода, и с возможностью построения стратегии с учетом логического и физического времени.

MARL (Multi-Agent Reinforcement Learning) — это обучение с подкреплением в многоагентных системах, где несколько агентов одновременно обучаются и взаимодействуют в одной среде. В отличие от обычного RL, MARL моделирует динамику, возникающую из взаимодействия агентов, включая координацию, конкуренцию, эмерджентное поведение и коллективные эффекты.

ZSC (Zero-Shot Coordination) это способность двух или более независимых агентов эффективно сотрудничать без предварительного совместного обучения, без обмена сигналами и без договорённостей. Это один из самых трудных открытых вопросов в современной многоагентной ИИ-науке.

План разработки

Мы предлагаем Python-фреймворк с ускорением на C++, совместимый с API PettingZoo Parallel (производительность >150 000 кадров в секунду), а также набор базовых алгоритмов (MAPPO, QMIX, Self-Play) и предварительно обученную популяцию из 100 агентов с высокой степенью разнообразия для оценки в режиме Cross-Play. Необходимость создания сред, проверяющих *чистую пространственную интуицию* и «модель разума» (Theory of Mind) без прямого обмена сигналами.

Related Work

Преимущества CTOR перед существующими средами (Hanabi, Overcooked, StarCraft II).

Обзор существующих бенчмарков для ZSC (Hanabi Challenge, Overcooked-AI, Diplomacy).

Методологии оценки координации с незнакомым партнером (Cross-Play, Other-Play, Fictitious Co-Play).

ZSC Evaluation Metrics & Protocols

Cross-Play (XP) Matrix: Оценка 100×100 агентов, обученных в независимых запусках.

Human-AI Teaming (HAT) Protocol: Методология проведения экспериментов «1 Человек + 1 ИИ».

Experimental Results & Baselines

Сравнение результатов базовых алгоритмов (MAPPO, QMIX, IPPO, Self-Play).

Оценки устойчивости свёрточных сетей (Circular CNN vs Standard CNN) к тороидальной топологии.

Применение методологии CTOR вне игр: рои дронов, управление автономным трафиком, симуляции биопопуляций.